

## Machine Learning

**Aufgabe 1.** Lineare Regression – MLE für  $\sigma^2$ 

6 P.

Es seien Einflussgrößen  $(\mathbf{x}_1, \dots, \mathbf{x}_n) \in \mathbb{R}^d$  und Zielgrößen  $(y_1, \dots, y_n) \in \mathbb{R}$  gegeben. Wir modellieren die Zielgrößen durch ein lineares Regressionsmodell der Form  $p(y_i | \mathbf{x}_i, \theta) = \mathcal{N}(y_i | \mathbf{w}^\top \mathbf{x}_i, \sigma^2)$ .

In der Vorlesung wurde gezeigt, dass der Maximum-Likelihood Schätzer für  $\mathbf{w}$  durch  $\hat{\mathbf{w}} = (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top \mathbf{y}$  gegeben ist. Wie schätzen nun den Varianzparameter  $\sigma^2$ .

- Geben Sie die NLL (negative log likelihood) Funktion unter den genannten Verteilungsannahmen an. Nutzen Sie dafür die Datenmatrix  $\mathbf{X} := (\mathbf{x}_1, \dots, \mathbf{x}_n)^\top$  und den Zielvektor  $\mathbf{y} = (y_1, \dots, y_n)^\top$ .
- Bestimmen Sie die Nullstelle  $\hat{\sigma}^2$  der partiellen Ableitung von  $\text{NLL}(\mathbf{w}, \sigma^2)$  nach  $\sigma^2$ .
- Bestimmen Sie die zweite partielle Ableitung von  $\text{NLL}(\mathbf{w}, \sigma^2)$  nach  $\sigma^2$  und zeigen Sie, dass diese an der Stelle  $\hat{\sigma}^2$  positiv ist.
- Genügen (b) und (c) um zu zeigen, dass  $(\hat{\mathbf{w}}, \hat{\sigma}^2)$  ein lokales Maximum der Likelihoodfunktion ist? Begründen Sie Ihre Antwort.

**Aufgabe 2.** Lineare Regression – Geometrische Interpretation

6 P.

In der Vorlesung wurde gezeigt, dass unter den Annahmen von Aufgabe 1 der Maximum-Likelihood Schätzer für  $\mathbf{w}$  durch  $\hat{\mathbf{w}} = (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top \mathbf{y}$  gegeben ist.

Die Vorhersage der Zielvariable ist demnach  $\hat{\mathbf{y}} = \mathbf{X} \hat{\mathbf{w}} = \mathbf{X} (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top \mathbf{y} = \mathbf{P} \mathbf{y}$ . Zeigen Sie, dass  $\mathbf{P} := \mathbf{X} (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top$  eine orthogonale Projektion auf den Spaltenraum von  $\mathbf{X}$  definiert, indem Sie zeigen, dass

- $\mathbf{P} \mathbf{P} = \mathbf{P}$
- Für jeden Vektor  $\mathbf{v} \in \mathbb{R}^n$  gilt  $\mathbf{P} \mathbf{v} \in \text{span}(\{\mathbf{x}_{:,i} : i = 1, \dots, d\})$ . D.h., zeigen Sie, dass es Faktoren  $a_1, \dots, a_d \in \mathbb{R}$  gibt, sodass  $\mathbf{P} \mathbf{v} = \sum_{i=1}^d a_i \mathbf{x}_{:,i}$ .
- Für jeden Spaltenvektor  $\mathbf{x}_{:,i}$  von  $\mathbf{X}$  und für alle  $\mathbf{v} \in \mathbb{R}^n$  ist  $\mathbf{v} - \mathbf{P} \mathbf{v}$  orthogonal zu  $\mathbf{x}_{:,i}$ .

**Aufgabe 3.** Lineare Regression – Beispiel 1

6 P.

Ein Gleichstrom-Motor erbrachte bei  $n = 8$  Messungen die folgenden Werte für die Leistung  $P$  [kW] in Abhängigkeit von der Drehzahl  $f$  [1000 U/min]:

$f_k$	0.8	1.5	2.5	3.5	4.2	4.7	5.0	5.5
$P_k$	8.8	14.7	22.8	29.4	38.2	44.1	47.8	51.5

- Zeichnen Sie die Messwerte (sauber!) in ein Koordinatensystem ein.
- In dem für den vorliegenden Fall von skalaren Einflussgrößen  $x_i \in \mathbb{R}$  reduziert sich das Regressionsmodell zu  $p(y_i | x_i, \theta) = \mathcal{N}(y_i | ax + b)$ . Leiten Sie die Maximum-Likelihood Schätzer für  $a$  und  $b$  aus der Formel  $\hat{\mathbf{w}} = (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top \mathbf{y}$  für den Fall von  $d = 1$  her.
- Berechnen Sie mit diesen Formeln (und einem Taschenrechner) die Regressionsgerade und zeichnen Sie diese (mit Lineal!) ein.
- Bestimmen Sie die Residuenquadratsumme (RSS) des Regressionsmodells.
- Bestimmen Sie aus der Regressionsgerade einen Schätzwert für die Motorleistung bei 4000 U/min und zeichnen Sie ihn ein.

**Aufgabe 4.** *Lineare Regression – Beispiel 2*

6 P.

Betrachten Sie das folgende lineare Regressionsmodell mit einer 2-dimensionalen Zielvariable  $y_i \in \mathbb{R}^2$  und einer binären Einflussgröße  $x_i \in \{0, 1\}$ .

Die Trainingsdaten sind wie in der Tabelle rechts angegeben. Zusätzlich, betten wir die Einflussgrößen folgendermaßen in  $\mathbb{R}^2$  ein:

$$\phi(0) = (1, 0)^\top, \quad \phi(1) = (0, 1)^\top,$$

sodass  $\mathbf{y} = \mathbf{W}^\top \phi(\mathbf{x})$  wobei  $\mathbf{W}$  eine  $2 \times 2$  Matrix ist.

Bestimmen Sie den Maximum-Likelihood Schätzer für  $\mathbf{W}$  mithilfe der Formel

$$\hat{\mathbf{W}} = (\phi(\mathbf{X})^\top \phi(\mathbf{X}))^{-1} \phi(\mathbf{X})^\top \mathbf{Y}.$$

$x$	$y$
0	$(-1, -1)^\top$
0	$(-1, -2)^\top$
0	$(-2, 1)^\top$
1	$(1, 1)^\top$
1	$(1, 2)^\top$
1	$(2, 1)^\top$